Universidad Internacional de la Rioja (UNIR)

Escuela Superior de Ingeniería y Tecnología

Máster en Inteligencia Artificial

Desarrollo de un Sistema Híbrido de Asistencia Clínica: Fine-Tuning de LLMs Open Source y Arquitectura RAG (Retrieval-Augmented Generation) para Medicina Basada en la Evidencia.

Trabajo Fin de Estudios

presentado por: David Solanas Sanz

Dirigido por: Andrés Soto Villaverde

Ciudad:Zaragoza

Fecha: 1 de junio de 2026

Índice de Contenidos

Resumen v

Abstract vi

1. Introducción 1

1.1. Motivación y justificación 1

1.2. Planteamiento del trabajo 2

1.3. Estructura del trabajo 3

2. Contexto y Estado del Arte 5

2.1. Sobrecarga informacional en el entorno clínico 5

2.2. Grandes Modelos de Lenguaje 6

2.2.1. Arquitectura Transformer 6

2.2.2. LLMs de última generación 6

2.3. Ajuste fino eficiente de LLMs 7

2.3.1. LoRA: adaptación de bajo rango 7

2.3.2. QLoRA: cuantización y paginación de gradientes 7

2.3.3. Ajuste fino supervisado e instruction-tuning 8

2.4. Retrieval-Augmented Generation 8

2.4.1. Fundamentos teóricos 8

2.4.2. RAG frente a ajuste fino: contribuciones diferenciales 9

2.5. Embeddings biomédicos 9

2.6. Bases de datos vectoriales y búsqueda de similitud 10

2.7. Alucinaciones en LLMs y marcos de evaluación 11

2.8. Aplicaciones de RAG y LLMs en entornos clínicos 11

2.9. Síntesis y brecha de la literatura 12

3. Objetivos y Metodología de Trabajo 14

3.1. Objetivo general 14

3.2. Objetivos específicos 14

3.3. Metodología de trabajo 15

3.4. Herramientas y tecnologías 16

3.5. Planificación temporal 16

4. Identificación de Requisitos **18**

5. Descripción de la Herramienta Software Desarrollada **19**

6. Evaluación **20**

7. Conclusiones y Trabajo Futuro **21**

Referencias 21

A. Apendices **25**

Índice de Ilustraciones

Índice de Tablas

3.1. Herramientas y tecnologías empleadas en el sistema 17
3.2. Planificación temporal del trabajo 17

Resumen

Nota: En este apartado se introducirá un breve resumen en español del trabajo realizado (extensión máxima: 150 palabras). Este resumen debe incluir el objetivo o propósito de la investigación, la metodología, los resultados y las conclusiones.

Palabras Clave: Se deben incluir de 3 a 5 palabras claves en español

Abstract

Nota: En este apartado se introducirá un breve resumen en español del trabajo realizado (extensión máxima: 150 palabras). Este resumen debe incluir el objetivo o propósito de la investigación, la metodología, los resultados y las conclusiones.

Palabras Clave: Se deben incluir de 3 a 5 palabras claves en inglés

1. Introducción

1.1. Motivación y justificación

La medicina actual se enfrenta al siguiente problema: el mismo crecimiento del conocimiento científico que debería mejorar la atención al paciente amenaza con desbordar la capacidad cognitiva del profesional clínico que ha de asimilarlo. (Rebitzer, Rege, y Shepard, 2008) identificaron este fenómeno como una forma específica de sobrecarga de información en el ámbito sanitario, argumentando que el volumen y la velocidad de publicación de nueva evidencia supera la capacidad individual de procesamiento de los médicos. Las consecuencias son las siguientes: adopción lenta de nuevos tratamientos, mayor probabilidad de pasar por alto hallazgos relevantes y, en última instancia, una reducción de la calidad asistencial. (Laker, Froehle, Windeler, y Lindsell, 2018) profundizaron en esta problemática, demostrando que la sobrecarga informacional no solo afecta a la velocidad de la toma de decisiones clínicas, sino también a su calidad, introduciendo sesgos sistemáticos porque el médico prioriza solo los datos que han sido resaltados, ignorando otros hechos que podrían ser igual de importantes.

Ante esta situación, los Grandes Modelos de Lenguaje (LLM, por sus siglas en inglés) han emergido como una tecnología con potencial para actuar como interfaz inteligente entre el profesional clínico y el corpus de literatura científica disponible. Modelos como GPT-4 (OpenAI y cols., 2024) y LLaMA (Grattafiori y cols., 2024) han demostrado capacidades notables de comprensión y generación de lenguaje natural, y revisiones sistemáticas recientes ya destacan su utilidad en tareas clínicas como asistencia al diagnóstico, triaje o soporte documental quirúrgico (Pressman y cols., 2024). Sin embargo, su aplicación directa en entornos clínicos presenta limitaciones críticas que impiden su adopción directa sin mediación técnica adicional. La más relevante es la tendencia de estos modelos a generar información plausible pero factualmente incorrecta, fenómeno conocido en la literatura como alucinación (Ji y cols., 2023). En el dominio sanitario, donde una respuesta incorrecta puede tener consecuencias directas sobre decisiones terapéuticas, esta limitación es inaceptable. (Pal, Umapathi, y Sankarasubbu, 2023) cuantificaron este riesgo específicamente en contextos médicos, evidenciando tasas de error significativas incluso en modelos de última generación cuando operan fuera de su distribución de entrenamiento.

Para mitigar estas limitaciones, la arquitectura Retrieval-Augmented Generation (RAG)

propuesta por (Lewis y cols., 2021) ofrece un marco técnico que combina la capacidad generativa de los LLM con la recuperación dinámica de información desde fuentes de conocimiento externas verificadas. En el dominio sanitario, (Amugongo, Mascheroni, Brooks, Doering, y Seidel, 2025) han revisado sistemáticamente la aplicación de RAG en entornos clínicos, concluyendo que la integración de bases de conocimiento biomédico estructuradas reduce significativamente la tasa de alucinaciones y mejora la trazabilidad de las respuestas generadas. Complementariamente, el ajuste fino (fine-tuning) de modelos base sobre corpus clínicos especializados, como los estudiados por (Lee y cols., 2020) y (Alsentzer y cols., 2019), ha demostrado mejorar la coherencia terminológica y la adecuación del formato de respuesta al contexto sanitario. No obstante, la evaluación comparativa y sistemática del efecto diferencial de cada componente (RAG y fine-tuning) sobre métricas específicas de calidad clínica mediante un diseño ablativo de cuatro configuraciones representa una contribución metodológica aún poco frecuente en la literatura.

Este trabajo se sitúa en la intersección de ambas líneas técnicas, proponiendo un sistema híbrido que combina el fine-tuning mediante QLoRA sobre datos clínicos con una arquitectura RAG conectada a PubMed, con el objetivo de construir un asistente de consulta bibliográfica para profesionales sanitarios que sea simultáneamente preciso, trazable y clínicamente coherente.

1.2. Planteamiento del trabajo

El objetivo principal de este Trabajo de Fin de Estudios es diseñar, implementar y evaluar un sistema híbrido de asistencia a la consulta bibliográfica clínica que combine fine-tuning eficiente de un LLM con una arquitectura RAG sobre literatura biomédica verificada, analizando la contribución diferencial de cada componente sobre la calidad de las respuestas generadas.

Los objetivos específicos que operacionalizan este propósito son los siguientes:

- Construir un pipeline de ingestión, fragmentación e indexación semántica de artículos biomédicos de PubMed en una base de datos vectorial, empleando embeddings especializados en dominio clínico.

- Realizar el ajuste fino del modelo LLaMA-3.1-8B mediante QLoRA sobre el corpus de transcripciones clínicas MTSamples, adaptando el estilo y la terminología de las respuestas al contexto sanitario.

- Integrar ambos módulos en una arquitectura híbrida gestionada mediante prácticas MLOps, garantizando la reproducibilidad y trazabilidad del ciclo experimental.
- Evaluar el sistema bajo cuatro configuraciones experimentales —modelo base, fine-tuning exclusivo, RAG exclusivo y sistema híbrido completo— con el fin de cuantificar la contribución individual de cada componente sobre métricas de calidad de recuperación y generación.
- Determinar si el sistema híbrido ofrece ventajas cuantificables sobre las configuraciones parciales, identificando qué limitación específica resuelve cada técnica.

La contribución diferencial de este trabajo respecto a los estudios previos reside en el diseño ablativo de la evaluación: frente a trabajos que evalúan RAG o fine-tuning de forma independiente, o que combinan ambas técnicas sin descomponer su efecto, este trabajo cuantifica explícitamente qué aporta cada componente por separado, aportando evidencia empírica sobre el rol complementario de ambas estrategias en un contexto de asistencia clínica basada en evidencia.

1.3. Estructura del trabajo

Este trabajo se organiza en siete capítulos, los cuales se organizan de la siguiente manera:

El **Capítulo 1 (Introducción)** presenta la problemática de la sobrecarga informacional en medicina, justifica la relevancia del trabajo y enuncia sus objetivos generales.

El **Capítulo 2 (Contexto y Estado del Arte)** revisa la literatura sobre los fundamentos técnicos del sistema: arquitecturas Transformer y LLMs, técnicas de ajuste fino eficiente (LoRA y QLoRA), la arquitectura RAG, los modelos de embeddings biomédicos, las bases de datos vectoriales y los marcos de evaluación. El capítulo concluye con una síntesis y brecha identificada en la literatura que justifica la contribución del trabajo.

El **Capítulo 3 (Objetivos y Metodología de Trabajo)** define los objetivos específicos del trabajo de forma SMART y describe la metodología seguida para alcanzarlos, incluyendo el diseño experimental ablativo de cuatro configuraciones, las herramientas empleadas y la planificación temporal.

El **Capítulo 4 (Identificación de Requisitos)** especifica los requisitos funcionales y no funcionales del sistema, el perfil de usuario objetivo y el proceso de validación de

requisitos.

El **Capítulo 5 (Descripción de la Herramienta Software Desarrollada)** detalla la arquitectura del sistema, los módulos implementados (ingestión, embeddings, fine-tuning, pipeline RAG e interfaz Gradio) y las decisiones de diseño adoptadas.

El **Capítulo 6 (Evaluación)** presenta los resultados de la evaluación automática mediante RAGAS para las cuatro configuraciones experimentales, así como la evaluación de usabilidad realizada con usuarios.

El **Capítulo 7 (Conclusiones y Trabajo Futuro)** resume las contribuciones del trabajo, relaciona los resultados con los objetivos planteados, expone las limitaciones identificadas y propone las líneas de trabajo futuro más prometedoras.

2. Contexto y Estado del Arte

Este capítulo presenta el contexto y estado del arte en las áreas tecnológicas y clínicas sobre las que se construye el sistema propuesto. En primer lugar, se presenta el problema de la sobrecarga informacional en medicina para justificar la necesidad de asistentes inteligentes de consulta bibliográfica, y posteriormente se revisan los fundamentos técnicos que los hacen posibles: arquitecturas Transformer y LLMs, técnicas de ajuste fino eficiente, la arquitectura RAG, los embeddings biomédicos, las bases de datos vectoriales, el fenómeno de las alucinaciones y los marcos de evaluación. El capítulo concluye con una síntesis y diferencias identificadas en la literatura que fundamenta la contribución específica de este trabajo.

2.1. Sobrecarga informacional en el entorno clínico

La literatura científica biomédica crece a un ritmo que supera la capacidad individual de procesamiento de los profesionales sanitarios. Rebitzer y cols. (2008) analizaron cómo los sistemas de información hospitalarios, paradójicamente, pueden amplificar la sobrecarga en lugar de aliviarla, al incrementar el volumen de datos accesibles sin proporcionar mecanismos de síntesis o priorización. Las consecuencias son directamente medibles: Laker y cols. (2018) demostraron mediante un experimento controlado con médicos de urgencias que la sobrecarga informacional degrada simultáneamente la velocidad y la calidad de la toma de decisiones clínicas, introduciendo sesgos de énfasis que llevan a ignorar datos potencialmente determinantes.

Este contexto hace que la consulta de literatura primaria (artículos, guías clínicas y revisiones sistemáticas) sea en la práctica inviable durante la jornada asistencial. La alternativa de delegar en buscadores genéricos o en resúmenes editoriales implica una pérdida de precisión y trazabilidad que resulta crítica en un entorno donde las decisiones tienen consecuencias directas sobre la salud de los pacientes. Es en este espacio de necesidad donde los asistentes de consulta bibliográfica basados en LLMs y arquitecturas RAG tienen el potencial de convertirse en una herramienta de impacto clínico real.

2.2. Grandes Modelos de Lenguaje

2.2.1. Arquitectura Transformer

La arquitectura Transformer, introducida por Vaswani y cols. (2017), estableció el paradigma computacional sobre el que se construyen todos los modelos de lenguaje actuales. Su contribución principal fue sustituir las redes recurrentes por un mecanismo de atención multi-cabeza (*multi-head self-attention*) que computa relaciones entre todos los pares de tokens de una secuencia en paralelo, eliminando la dependencia secuencial que limitaba la paralelización y la captura de dependencias de largo alcance. La fórmula de atención es:

$$\text{Attention}(Q, K, V) = \text{softmax}\left(\frac{QK^\top}{\sqrt{d_k}}\right) V \tag{2.1}$$

donde Q, K y V son las matrices de consulta (*query*), clave (*key*) y valor (*value*) proyectadas desde la representación de entrada, es el núcleo de todos los modelos revisados en este capítulo.

Devlin, Chang, Lee, y Toutanova (2019) aplicaron la arquitectura Transformer encoder-only para introducir BERT (*Bidirectional Encoder Representations from Transformers*), estableciendo el paradigma de preentrenamiento masivo con ajuste fino (*pretraining + fine-tuning*). BERT se preentrenó sobre texto no etiquetado con dos objetivos: modelado de lenguaje enmascarado (MLM) y predicción de la siguiente oración (NSP), produciendo representaciones contextuales densas que se convirtieron en la base de los modelos de embeddings biomédicos.

2.2.2. LLMs de última generación

El preentrenamiento Transformer dio lugar a los LLMs actuales, modelos con miles de millones de parámetros capaces de razonar y generar texto en prácticamente cualquier dominio. Entre los modelos propietarios, GPT-4 (OpenAI y cols., 2024) representa el estado del arte en capacidades de razonamiento general, aunque su aplicación en entornos clínicos está condicionada por las restricciones de privacidad que impone el envío de datos a infraestructura de terceros.

En el espacio de código abierto, la familia LLaMA-3 de Meta AI (Grattafiori y cols., 2024) ha demostrado capacidades de razonamiento comparables a los modelos propietarios en múltiples benchmarks, con la ventaja de poder desplegarse en infraestructura propia. El modelo LLaMA-3.1-8B-Instruct, variante ajustada con instrucciones, es especialmente

relevante para este trabajo por su capacidad de seguir instrucciones estructuradas en formato sistema/usuario/asistente y por su viabilidad de despliegue en GPU con memoria de 10 GB mediante cuantización de 4 bits. Revisiones sistemáticas recientes sobre LLMs en entornos clínicos (Pressman y cols., 2024) identifican asistencia diagnóstica, triaje y soporte documental como los campos de aplicación más maduros, aunque señalan limitaciones críticas de precisión factual que justifican la combinación con sistemas de recuperación de información.

2.3. Ajuste fino eficiente de LLMs

El ajuste fino (*fine-tuning*) completo de un LLM de miles de millones de parámetros requiere recursos computacionales fuera del alcance de la mayoría de equipos de investigación. Las técnicas de ajuste fino eficiente abordan esta limitación reduciendo drásticamente el número de parámetros entrenables sin sacrificar el rendimiento final.

2.3.1. LoRA: adaptación de bajo rango

Hu y cols. (2021) propusieron LoRA (*Low-Rank Adaptation*), que congela los pesos preentrenados del modelo base y añade matrices de adaptación de bajo rango a las capas de proyección de la atención. Para una capa con matriz de pesos $W_0 \in \mathbb{R}^{d\times k}$, la actualización se aproxima como:

$$W = W_0 + \Delta W = W_0 + BA \tag{2.2}$$

donde $B \in \mathbb{R}^{d\times r}$ y $A \in \mathbb{R}^{r\times k}$, con rango $r \ll \text{mín}(d, k)$. Solo se optimizan las matrices A y B, reduciendo el número de parámetros entrenables en varios órdenes de magnitud. En los experimentos del trabajo original, LoRA igualó el rendimiento del ajuste fino completo en tareas de lenguaje natural con una fracción del coste computacional.

2.3.2. QLoRA: cuantización y paginación de gradientes

Dettmers, Pagnoni, Holtzman, y Zettlemoyer (2023) extendieron LoRA con tres innovaciones que hicieron posible el ajuste fino de modelos de 65B parámetros en una única GPU: (1) cuantización del modelo base a 4 bits en formato NF4 (*NormalFloat4*), un tipo de dato óptimo para pesos con distribución normal; (2) cuantización doble (*Double Quantization*) de las constantes de cuantización para reducir el uso de memoria adicional; y (3) optimizadores paginados que transfieren estados del optimizador a RAM cuando la

VRAM se satura. La combinación permite ajustar LLaMA-3.1-8B en 8–10 GB de VRAM con una pérdida de precisión inferior al 1 % respecto al ajuste fino completo en FP16. Esta técnica es la que se emplea en este trabajo, implementada a través de la librería Unsloth, que añade optimizaciones de kernels CUDA sobre la implementación original de QLoRA.

Parthasarathy, Zafar, Khan, y Shahid (2024) ofrecen una revisión exhaustiva del ecosistema de ajuste fino, documentando las variantes más relevantes y las mejores prácticas de selección de hiperparámetros, lo que permite contextualizar las decisiones metodológicas de este trabajo.

2.3.3. Ajuste fino supervisado e instruction-tuning

Más allá de los mecanismos de eficiencia descritos, resulta relevante distinguir el *objetivo de entrenamiento* aplicado. El ajuste fino por continuación de preentrenamiento (*continued pretraining*) expone el modelo a texto de dominio sin estructura adicional, mejorando la familiaridad con la terminología pero sin orientar el comportamiento generativo hacia un formato de interacción concreto. El ajuste fino supervisado (*Supervised Fine-Tuning*, SFT) o *instruction-tuning*, en cambio, entrena el modelo sobre pares de instrucción-respuesta, enseñándole a seguir directrices explícitas y a producir salidas en el formato esperado por el usuario (Parthasarathy y cols., 2024). Esta distinción es relevante en el dominio clínico: un modelo entrenado únicamente sobre texto médico genérico puede adquirir vocabulario especializado sin aprender a estructurar respuestas de forma coherente con una consulta bibliográfica. El SFT sobre transcripciones clínicas formateadas como instrucciones permite combinar ambos beneficios: adaptación terminológica y adecuación del estilo de respuesta al contexto de asistencia.

2.4. Retrieval-Augmented Generation

2.4.1. Fundamentos teóricos

La arquitectura Retrieval-Augmented Generation (RAG) fue introducida por Lewis y cols. (2021) como respuesta a las limitaciones de los LLMs para tareas de conocimiento intensivo (*knowledge-intensive tasks*): el conocimiento del modelo queda congelado en el momento del entrenamiento, no puede actualizarse sin reentrenamiento y no ofrece trazabilidad de las fuentes que fundamentan sus respuestas. RAG propone combinar un componente paramétrico (el LLM) con un componente no paramétrico (un índice denso

de documentos), de modo que ante una consulta q, el sistema recupera los documentos más relevantes $z_1, \ldots, z_k$ y los incorpora al contexto de generación:

$$p(y \mid x) = \sum_{z \in \mathcal{Z}} p_\eta(z \mid x)\, p_\theta(y \mid x, z) \tag{2.3}$$

donde p_η es el retriever (en el trabajo original, DPR) y p_θ es el generador.

Esta arquitectura presenta ventajas directamente relevantes para el dominio clínico: la base de conocimiento puede actualizarse sin reentrenar el LLM, cada respuesta es trazable a fragmentos de documentos concretos con identificador PMID, y la recuperación actúa como restricción factual que reduce la generación de contenido inventado.

2.4.2. RAG frente a ajuste fino: contribuciones diferenciales

Una serie de estudios de investigación analizan cuándo conviene RAG, cuándo ajuste fino y cuándo ambas técnicas de forma combinada. Ovadia, Brief, Mishaeli, y Elisha (2024) compararon ambas estrategias en tareas de inyección de conocimiento y concluyeron que RAG supera consistentemente al ajuste fino no supervisado en la incorporación de hechos nuevos, mientras que el ajuste fino aporta adaptación estilística y terminológica que RAG no puede proporcionar. Esta complementariedad es el fundamento teórico del diseño ablativo de cuatro configuraciones adoptado en este trabajo.

Balaguer y cols. (2024) validaron empíricamente este diseño en un dominio especializado (agronomía), comparando las configuraciones base, FT, RAG y FT+RAG, y observando ganancias de precisión acumulativas: aproximadamente 6 puntos porcentuales aportados por el ajuste fino y 5 puntos adicionales por RAG. En el ámbito médico específicamente, Pingua y cols. (2025) replicaron la comparativa sobre datos sanitarios con múltiples LLMs, encontrando que LLaMA supera a los modelos alternativos en la configuración FT+RAG y que RAG reduce la tasa de alucinaciones de manera más efectiva que el ajuste fino aislado. A nivel de síntesis, Collaco y cols. (2026) revisaron sistemáticamente los sistemas híbridos FT+RAG en sanidad, concluyendo que la combinación supera consistentemente a cualquiera de las dos técnicas por separado en precisión y reducción de alucinaciones.

2.5. Embeddings biomédicos

La calidad de la recuperación en un sistema RAG depende críticamente del modelo de representación semántica. Los modelos de embeddings de dominio general suelen subesti-

mar la especificidad terminológica del texto clínico y biomédico, lo que justifica el uso de modelos preentrenados sobre corpus especializados.

Lee y cols. (2020) introdujeron BioBERT, que adapta la arquitectura BERT de Devlin y cols. (2019) continuando el preentrenamiento sobre abstracts de PubMed y artículos de texto completo de PubMed Central (PMC). El preentrenamiento en el dominio médico mejora de forma consistente el rendimiento en tareas de reconocimiento de entidades biomédicas (NER), extracción de relaciones y pregunta-respuesta sobre textos científicos. Alsentzer y cols. (2019) propusieron ClinicalBERT, preentrenado sobre notas clínicas del corpus MIMIC-III, orientado a documentación hospitalaria interna en lugar de literatura científica; esta distinción motiva la elección de BioBERT sobre ClinicalBERT cuando la base de conocimiento está formada por abstracts de PubMed.

Gu y cols. (2021) demostraron que el preentrenamiento *desde cero* sobre PubMed (en lugar de adaptar un modelo BERT general) produce representaciones superiores en el benchmark BLURB, que agrega 8 tareas de NLP biomédico. Su variante optimizada para abstracts, *BiomedNLP-BiomedBERT-base-uncased-abstract*, es un candidato para sistemas RAG cuyo corpus de recuperación está formado por abstracts de PubMed. Fang, Chen, Wei, Lu, y Wang (2023) presentaron Bioformer, un modelo un 40 % más pequeño que PubMedBERT que mantiene una diferencia de rendimiento inferior al 1 % en los mismos benchmarks BLURB, con la ventaja adicional de haber sido preentrenado sobre PubMed y texto completo de PubMed Central (PMC). La selección empírica entre ambos modelos para el pipeline de este trabajo se detalla en el Capítulo 5.

2.6. Bases de datos vectoriales y búsqueda de similitud

El componente no paramétrico de RAG requiere estructuras de datos especializadas para la búsqueda eficiente de vecinos aproximados (*Approximate Nearest Neighbor*, ANN) en espacios de alta dimensionalidad. Malkov y Yashunin (2020) propusieron HNSW (*Hierarchical Navigable Small World*), un grafo de proximidad multicapa que permite búsquedas ANN con complejidad logarítmica y alta tasa de recuperación. HNSW es el algoritmo de indexación que implementa Qdrant, el motor de bases de datos vectoriales empleado en este trabajo. Johnson, Douze, y Jegou (2021) presentaron FAISS, la librería de búsqueda vectorial de Meta AI orientada a GPU y con capacidad para escalar a miles de millones de vectores. La elección de Qdrant frente a alternativas como FAISS o Pinecone se justi-

fica por su soporte nativo para filtrado por metadatos (año de publicación, especialidad médica) en la misma consulta de búsqueda vectorial, eliminando la necesidad de un paso de post-filtrado que puede provocar la reducción de la precisión de recuperación.

2.7. Alucinaciones en LLMs y marcos de evaluación

Ji y cols. (2023) presentan el fenómeno de alucinación en modelos de lenguaje: la generación de texto coherente y gramaticalmente correcto que no se corresponde con hechos verificables ni con el contexto de entrada. La revisión distingue alucinaciones intrínsecas (contradicción con la fuente de entrada) y extrínsecas (información no verificable), y documenta la prevalencia del problema en modelos generativos independientemente de su tamaño. En el dominio médico, la magnitud del problema es especialmente grave: Pal y cols. (2023) diseñaron Med-HALT, un benchmark específico para alucinaciones médicas que incluye pruebas de memoria y razonamiento, y documentaron tasas de error significativas en LLMs de última generación cuando operan sobre preguntas clínicas fuera de su distribución de entrenamiento.

Para la evaluación cuantitativa de sistemas RAG, Es, James, Espinosa-Anke, y Schockaert (2025) propusieron RAGAS (*Retrieval Augmented Generation Assessment*), un framework de evaluación automatizada sin referencias (*reference-free*) que mide cuatro dimensiones: *Faithfulness* (fidelidad de la respuesta al contexto recuperado), *Answer Relevancy* (relevancia de la respuesta a la pregunta), *Context Precision* (proporción de fragmentos recuperados que son realmente útiles) y *Context Recall* (cobertura de la información necesaria por el contexto recuperado). RAGAS es el marco de evaluación principal de este trabajo, empleado para comparar las cuatro configuraciones experimentales sobre un benchmark de preguntas clínicas.

2.8. Aplicaciones de RAG y LLMs en entornos clínicos

Amugongo y cols. (2025) ofrecen la revisión sistemática más reciente y exhaustiva de sistemas RAG aplicados en sanidad, identificando tres variantes (RAG Naive, RAG avanzado y RAG modular) y documentando la dominancia de modelos propietarios (GPT-3.5/4) en los estudios publicados, así como la ausencia de marcos de evaluación estandarizados. Esta brecha (modelos propietarios y evaluación ad-hoc) es precisamente el espacio que este trabajo busca abordar con LLaMA-3 de código abierto y evaluación sistemática mediante

RAGAS.

En cuanto a aplicaciones concretas, Rau y cols. (2023) demostraron que un chatbot RAG construido sobre LlamaIndex y GPT-3.5-turbo supera a radiólogos expertos y a ChatGPT genérico en el seguimiento de las guías de adecuación del American College of Radiology, reduciendo el tiempo de decisión de 50 a 5 minutos. Yu, Guo, y Sano (2023) aplicaron RAG en modalidad *zero-shot* para el diagnóstico de arritmias y apnea del sueño a partir de señales ECG, ilustrando la versatilidad del paradigma más allá del texto. Thompson y cols. (2023) emplearon RAG con MapReduce para la fenotipización de hipertensión pulmonar en historias clínicas electrónicas, superando la lógica de reglas diseñada por médicos (F1: 0,75 vs. 0,62), lo que resulta especialmente relevante como referencia comparativa dado que MTSamples es un corpus de características similares: texto clínico no estructurado con escasez de datos etiquetados.

2.9. Síntesis y brecha de la literatura

La revisión anterior permite identificar las siguientes conclusiones que orientan el diseño del sistema propuesto:

- Los LLMs de código abierto como LLaMA-3 han alcanzado un nivel de capacidad que los hace viables para aplicaciones clínicas, pero su uso directo sin ajuste fino ni grounding factual produce tasas de error inaceptables en términos médicos (Pal y cols., 2023).
- El ajuste fino (QLoRA) y RAG son técnicas complementarias que mitigan problemas distintos: el primero adapta el estilo y la terminología clínica, el segundo aporta evidencia actualizada y trazabilidad (Ovadia y cols., 2024).
- La combinación FT+RAG demuestra ventajas cuantificables sobre cualquiera de las técnicas por separado, tanto en dominios generales (Balaguer y cols., 2024) como en el ámbito médico específico (Pingua y cols., 2025; Collaco y cols., 2026).
- Los sistemas RAG clínicos publicados se apoyan mayoritariamente en modelos propietarios con evaluación ad-hoc, sin un diseño ablativo que cuantifique la contribución diferencial de cada componente (Amugongo y cols., 2025).

La brecha identificada es, por tanto, la ausencia de un sistema híbrido de código abierto (LLM + QLoRA + RAG sobre PubMed) evaluado sistemáticamente mediante un diseño

ablativo de cuatro configuraciones con métricas RAGAS estandarizadas en el ámbito de la asistencia bibliográfica clínica. Este trabajo pretende cubrir ese espacio.

3. Objetivos y Metodología de Trabajo

Este capítulo presenta los objetivos del trabajo en términos medibles y describe la metodología seguida para alcanzarlos. Se parte del objetivo general enunciado en la introducción y se descompone en objetivos específicos que guían cada fase del desarrollo.

3.1. Objetivo general

El objetivo general de este trabajo es diseñar, implementar y evaluar un sistema híbrido de asistencia bibliográfica clínica que combine el ajuste fino eficiente de un LLM de código abierto con una arquitectura RAG sobre literatura biomédica verificada, cuantificando la contribución diferencial de cada componente sobre la calidad de las respuestas generadas.

Expresado en términos SMART (Doran, 1981): el objetivo es construir un sistema funcional, evaluado automáticamente mediante RAGAS y validado por al menos un profesional sanitario, que en la configuración híbrida completa (FT+RAG) obtenga una puntuación de *Faithfulness* superior a 0,90 y una *Context Precision* superior a 0,80.

3.2. Objetivos específicos

Para lograr el objetivo general, se plantean los siguientes objetivos específicos:

1. **OE1: Pipeline de ingestión semántica.** Construir un pipeline de descarga, fragmentación e indexación semántica de artículos biomédicos de PubMed en una base de datos vectorial Qdrant, empleando un modelo de embeddings especializado en texto biomédico, de modo que la colección contenga al menos 10.000 fragmentos indexados para las especialidades médicas objetivo.

2. **OE2: Ajuste fino del LLM.** Realizar el ajuste fino del modelo LLaMA-3.1-8B (Grattafiori y cols., 2024) mediante QLoRA (Dettmers y cols., 2023) sobre el corpus MTSamples (Boyle, 2017), adaptando el estilo y la terminología de las respuestas al contexto clínico.

3. **OE3: Integración en arquitectura híbrida con MLOps.** Integrar el módulo

de ajuste fino y el pipeline RAG en una arquitectura unificada gestionada mediante MLflow, garantizando la trazabilidad de todos los experimentos y la reproducibilidad de resultados.

4. **OE4: Evaluación ablativa en cuatro configuraciones.** Evaluar el sistema bajo cuatro configuraciones experimentales (modelo base (A), ajuste fino exclusivo (B), RAG exclusivo (C) y sistema híbrido completo (D)) sobre un benchmark de 50 preguntas clínicas, midiendo *Faithfulness*, *Answer Relevancy*, *Context Precision* y *Context Recall* mediante RAGAS (Es y cols., 2025).

5. **OE5: Determinación de la contribución diferencial.** Determinar si la configuración híbrida FT+RAG ofrece ventajas estadísticamente interpretables sobre las configuraciones parciales, identificando qué limitación específica mitiga cada técnica: el ajuste fino para la adaptación de estilo y terminología clínica, y RAG para la reducción de alucinaciones y la incorporación de evidencia actualizada.

6. **OE6: Desarrollo de un prototipo funcional de interfaz clínica.** Implementar una interfaz web funcional con Gradio que permita a un profesional sanitario formular consultas bibliográficas en lenguaje natural, seleccionar la configuración del sistema (Base / FT / RAG / FT+RAG), y visualizar las respuestas generadas junto con las fuentes bibliográficas recuperadas (PMID y fragmento de abstract), verificando su usabilidad mediante una sesión de evaluación con al menos un experto del dominio clínico.

3.3. Metodología de trabajo

La metodología propuesta en este trabajo está estructurada en las siguientes fases:

Fase 1: Adquisición y preparación de datos. Se descargan abstracts de PubMed para las especialidades médicas objetivo mediante la API Entrez de NCBI, utilizando una estrategia de ingestión por especialidad para minimizar las llamadas a la API. Paralelamente, los registros del corpus MTSamples se transforman al formato instrucción-respuesta (sistema/usuario/asistente) para el ajuste fino supervisado.

Fase 2: Construcción del índice vectorial. Los abstracts de PubMed se fragmentan en chunks y se codifican con el modelo de embeddings *Bioformer-16L* (Fang y cols., 2023). Los vectores se indexan en Qdrant con distancia coseno y metadatos de año y categoría

MeSH.

Fase 3: Ajuste fino QLoRA. El modelo base LLaMA-3.1-8B-Instruct se ajusta mediante la librería Unsloth. Los experimentos necesarios para lograr el ajuste fino se registran en MLflow.

Fase 4: Construcción del pipeline RAG. Se implementa un pipeline de recuperación augmentada que, ante una consulta clínica, (a) genera su embedding, (b) recupera los k fragmentos más similares de Qdrant filtrados por año, y (c) concatena el contexto recuperado al prompt del LLM con baja temperatura para mejorar la coherencia.

Fase 5: Evaluación. Se construye un benchmark de 50 preguntas clínicas con respuestas de referencia extraídas de guías clínicas y revisiones sistemáticas. Las cuatro configuraciones experimentales se evalúan automáticamente con RAGAS y mediante una sesión de evaluación de usabilidad con al menos un profesional sanitario.

Fase 6: Interfaz de demostración. Se implementa una interfaz web con Gradio que permite seleccionar la configuración del sistema y visualizar las respuestas junto con las fuentes recuperadas (PMID y fragmento de abstract).

3.4. Herramientas y tecnologías

La Tabla 3.1 resume las principales herramientas empleadas en cada módulo del sistema, con la justificación de su selección.

3.5. Planificación temporal

El desarrollo del trabajo se distribuye entre febrero y junio de 2026, organizándose en las seis fases descritas en la sección anterior. La Tabla 3.2 muestra la distribución temporal orientativa por mes.

Componente	**Herramienta**	**Justificación**
LLM base	LLaMA-3.1-8B-Instruct	Código abierto, 8B caben en 10 GB VRAM con cuantización
Fine-tuning	Unsloth + QLoRA	Reduce uso de memoria 4×; mayor velocidad vs. HuggingFace nativo
Embeddings	Bioformer-16L (384d)	Preentrenado en PubMed + PMC; supera a PubMedBERT en benchmark proxy (24/24 categorías MeSH)
Vector DB	Qdrant (Docker)	Soporte HNSW + filtrado por metadatos; API REST sencilla
Orquestación RAG	LlamaIndex	Framework validado en entornos clínicos (Rau y cols., 2023)
Evaluación	RAGAS	Evaluación automatizada sin referencias para pipelines RAG (Es y cols., 2025)
MLOps	MLflow (Docker)	Registro de hiperparámetros, métricas y artefactos por experimento
Interfaz	Gradio	Prototipado rápido de interfaces NLP sin frontend dedicado
Gestor de paquetes	uv	Resolución y bloqueo de dependencias 10-100× más rápido que pip

Tabla 3.1: Herramientas y tecnologías empleadas en el sistema

Fase	**Feb**	**Mar**	**Abr**	**May**	**Jun**
F1: Datos y bibliografía	•	•			
F2: Índice vectorial (RAG)		•	•		
F3: Ajuste fino QLoRA			•	•	
F4: Pipeline RAG				•	
F5: Evaluación				•	•
F6: Interfaz Gradio					•
Redacción memoria	•	•	•	•	•

Tabla 3.2: Planificación temporal del trabajo

4. Identificación de Requisitos

5. Descripción de la Herramienta Software Desarrollada

6. Evaluación

7. Conclusiones y Trabajo Futuro

Referencias

Alsentzer, E., Murphy, J. R., Boag, W., Weng, W.-H., Jin, D., Naumann, T., y McDermott, M. B. A. (2019, junio). *Publicly Available Clinical BERT Embeddings.* arXiv. Descargado 2025-12-11, de `http://arxiv.org/abs/1904.03323` (arXiv:1904.03323 [cs]) doi: 10.48550/arXiv.1904.03323

Amugongo, L. M., Mascheroni, P., Brooks, S., Doering, S., y Seidel, J. (2025, junio). Retrieval augmented generation for large language models in healthcare: A systematic review. *PLOS Digital Health*, *4*(6), e0000877. Descargado 2025-12-11, de `https://journals.plos.org/digitalhealth/article?id=10.1371/journal.pdig.0000877` doi: 10.1371/journal.pdig.0000877

Balaguer, A., Benara, V., de Freitas Cunha, R. L., de M. Estevão Filho, R., Hendry, T., Holstein, D., ... Chandra, R. (2024). *Rag vs fine-tuning: Pipelines, tradeoffs, and a case study on agriculture.* Descargado de `https://arxiv.org/abs/2401.08406`

Boyle, T. (2017). *Medical transcriptions.* Kaggle. Descargado de `https://www.kaggle.com/datasets/tboyle10/medicaltranscriptions` (Dataset scraped from `https://www.mtsamples.com`. License: CC0 Public Domain. Accessed 2026.)

Collaco, B. G., Srinivasagam, P., Gomez-Cabello, C. A., Haider, S. A., Genovese, A., Wood, N. G., ... Forte, A. J. (2026). Integrating fine-tuning and retrieval-augmented generation for healthcare ai systems: A scoping review. *Bioengineering*, *13*(2). Descargado de `https://www.mdpi.com/2306-5354/13/2/225` doi: 10.3390/bioengineering13020225

Dettmers, T., Pagnoni, A., Holtzman, A., y Zettlemoyer, L. (2023). *Qlora: Efficient finetuning of quantized llms.* Descargado de `https://arxiv.org/abs/2305.14314`

Devlin, J., Chang, M.-W., Lee, K., y Toutanova, K. (2019, junio). BERT: Pre-training of deep bidirectional transformers for language understanding. En J. Burstein, C. Doran, y T. Solorio (Eds.), *Proceedings of the 2019 conference of the north American chapter of the association for computational linguistics: Human language technologies, volume 1 (long and short papers)* (pp. 4171–4186). Minneapolis, Minnesota: Association for Computational Linguistics. Descargado de `https://aclanthology.org/N19-1423/` doi: 10.18653/v1/N19-1423

Doran, G. T. (1981). There's a smart way to write managements's goals and objectives. *Management review*, *70*(11).

Es, S., James, J., Espinosa-Anke, L., y Schockaert, S. (2025). *Ragas: Automated evaluation of retrieval augmented generation.* Descargado de https://arxiv.org/abs/2309.15217

Fang, L., Chen, Q., Wei, C.-H., Lu, Z., y Wang, K. (2023). *Bioformer: an efficient transformer language model for biomedical text mining.* Descargado de https://arxiv.org/abs/2302.01588

Grattafiori, A., Dubey, A., Jauhri, A., Pandey, A., Kadian, A., Al-Dahle, A., ... Ma, Z. (2024). *The llama 3 herd of models.* Descargado de https://arxiv.org/abs/2407.21783

Gu, Y., Tinn, R., Cheng, H., Lucas, M., Usuyama, N., Liu, X., ... Poon, H. (2021, octubre). Domain-specific language model pretraining for biomedical natural language processing. *ACM Transactions on Computing for Healthcare*, *3*(1), 1–23. Descargado de http://dx.doi.org/10.1145/3458754 doi: 10.1145/3458754

Hu, E. J., Shen, Y., Wallis, P., Allen-Zhu, Z., Li, Y., Wang, S., ... Chen, W. (2021). *Lora: Low-rank adaptation of large language models.* Descargado de https://arxiv.org/abs/2106.09685

Ji, Z., Lee, N., Frieske, R., Yu, T., Su, D., Xu, Y., ... Fung, P. (2023, marzo). Survey of Hallucination in Natural Language Generation. *ACM Comput. Surv.*, *55*(12), 248:1–248:38. Descargado 2025-12-11, de https://doi.org/10.1145/3571730 doi: 10.1145/3571730

Johnson, J., Douze, M., y Jegou, H. (2021, julio). Billion-Scale Similarity Search with GPUs. *IEEE Transactions on Big Data*, *7*(3), 535–547. Descargado 2026-04-13, de https://ieeexplore.ieee.org/document/8733051/ doi: 10.1109/TBDATA.2019.2921572

Laker, L. F., Froehle, C. M., Windeler, J. B., y Lindsell, C. J. (2018, diciembre). Quality and Efficiency of the Clinical Decision-Making Process: Information Overload and Emphasis Framing. *Production and Operations Management*, *27*(12), 2213–2225. Descargado 2025-12-11, de https://doi.org/10.1111/poms.12777 doi: 10.1111/poms.12777

Lee, J., Yoon, W., Kim, S., Kim, D., Kim, S., So, C. H., y Kang, J. (2020, febrero). BioBERT: a pre-trained biomedical language representation model for biomedical

text mining. *Bioinformatics*, *36*(4), 1234–1240. Descargado 2025-12-11, de https://doi.org/10.1093/bioinformatics/btz682 doi: 10.1093/bioinformatics/btz682

Lewis, P., Perez, E., Piktus, A., Petroni, F., Karpukhin, V., Goyal, N., ... Kiela, D. (2021, abril). *Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks.* arXiv. Descargado 2025-12-11, de http://arxiv.org/abs/2005.11401 (arXiv:2005.11401 [cs]) doi: 10.48550/arXiv.2005.11401

Malkov, Y. A., y Yashunin, D. A. (2020, abril). Efficient and Robust Approximate Nearest Neighbor Search Using Hierarchical Navigable Small World Graphs. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, *42*(4), 824–836. Descargado 2026-04-13, de https://ieeexplore.ieee.org/document/8594636/ doi: 10.1109/TPAMI.2018.2889473

OpenAI, Achiam, J., Adler, S., Agarwal, S., Ahmad, L., Akkaya, I., ... Zoph, B. (2024, marzo). *GPT-4 Technical Report.* arXiv. Descargado 2025-12-11, de http://arxiv.org/abs/2303.08774 (arXiv:2303.08774 [cs]) doi: 10.48550/arXiv.2303.08774

Ovadia, O., Brief, M., Mishaeli, M., y Elisha, O. (2024). *Fine-tuning or retrieval? comparing knowledge injection in llms.* Descargado de https://arxiv.org/abs/2312.05934

Pal, A., Umapathi, L. K., y Sankarasubbu, M. (2023, octubre). *Med-HALT: Medical Domain Hallucination Test for Large Language Models.* arXiv. Descargado 2025-12-11, de http://arxiv.org/abs/2307.15343 (arXiv:2307.15343 [cs]) doi: 10.48550/arXiv.2307.15343

Parthasarathy, V. B., Zafar, A., Khan, A., y Shahid, A. (2024, octubre). *The Ultimate Guide to Fine-Tuning LLMs from Basics to Breakthroughs: An Exhaustive Review of Technologies, Research, Best Practices, Applied Research Challenges and Opportunities.* arXiv. Descargado 2025-12-11, de http://arxiv.org/abs/2408.13296 (arXiv:2408.13296 [cs]) doi: 10.48550/arXiv.2408.13296

Pingua, B., Sahoo, A., Kandpal, M., Murmu, D., Rautaray, J., Barik, R. K., y Saikia, M. J. (2025). Medical llms: Fine-tuning vs. retrieval-augmented generation. *Bioengineering*, *12*(7). Descargado de https://www.mdpi.com/2306-5354/12/7/687 doi: 10.3390/bioengineering12070687

Pressman, S. M., Borna, S., Gomez-Cabello, C. A., Haider, S. A., Haider, C. R., y Forte, A. J. (2024). Clinical and surgical applications of large language models: A systematic review. *Journal of Clinical Medicine*, *13*(11). Descargado de

https://www.mdpi.com/2077-0383/13/11/3041 doi: 10.3390/jcm13113041

Rau, A., Rau, S., Zöller, D., Fink, A., Tran, H., Wilpert, C., ... Russe, M. F. (2023, julio). A Context-based Chatbot Surpasses Radiologists and Generic ChatGPT in Following the ACR Appropriateness Guidelines. *Radiology*, *308*(1), e230970. Descargado 2025-12-11, de https://pubs.rsna.org/doi/10.1148/radiol.230970 doi: 10.1148/radiol.230970

Rebitzer, J. B., Rege, M., y Shepard, C. (2008). Influence, information overload, and information technology in health care. En *Advances in Health Economics and Health Services Research* (Vol. 19, pp. 43–69). Bingley: Emerald (MCB UP). Descargado 2025-12-10, de http://www.emerald.com/books/edited-volume/11590/chapter/81491821 doi: 10.1016/S0731-2199(08)19003-3

Thompson, W. E., Vidmar, D. M., Freitas, J. K. D., Pfeifer, J. M., Fornwalt, B. K., Chen, R., ... Miotto, R. (2023, diciembre). *Large Language Models with Retrieval-Augmented Generation for Zero-Shot Disease Phenotyping.* arXiv. Descargado 2025-12-11, de http://arxiv.org/abs/2312.06457 (arXiv:2312.06457 [cs]) doi: 10.48550/arXiv.2312.06457

Vaswani, A., Shazeer, N., Parmar, N., Uszkoreit, J., Jones, L., Gomez, A. N., ... Polosukhin, I. (2017). Attention is all you need. En I. Guyon y cols. (Eds.), *Advances in neural information processing systems* (Vol. 30). Curran Associates, Inc. Descargado de https://proceedings.neurips.cc/paper_files/paper/2017/file/3f5ee243547dee91fbd053c1c4a845aa-Paper.pdf

Yu, H., Guo, P., y Sano, A. (2023, diciembre). Zero-Shot ECG Diagnosis with Large Language Models and Retrieval-Augmented Generation. En *Proceedings of the 3rd Machine Learning for Health Symposium* (pp. 650–663). PMLR. Descargado 2025-12-11, de https://proceedings.mlr.press/v225/yu23b.html

A. Apendices